OpenClassrooms

Projet 7 : DATA SCIENCE

Implémentez un modèle de scoring

INTRODUCTION

Data Scientist pour la banque
"Prêt à dépenser"

Prêt à dépenser

Objectif : Catégoriser les demandes de prêt des nouveaux clients

Classification

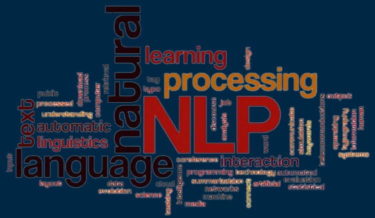

À partir des données clients

Pour répondre à leur demande

Prêt accordé

Prêt refusé

SOMMAIRE

01

ANALYSE EXPLORATOIRE

Découverte du fichier de données

02

ENTRAINEMENT DES MODELES

Choix des modèles, de la métrique et de la technique d'échantillonnage

03

DASHBOARD ET API

Présentation du dashboard Streamlit et de l'API FastAPI

ANALYSE EXPLORATOIRE

01

Découverte du jeu de données

DATAFRAME INITIAL

2 Dataframes :

- Train : 307 511 lignes et 122 colonnes

SK_ID_CURR	TARGET	NAME_CONTRACT_TYPE	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	CNT_CHILDREN	AMT_INCOME_TOTAL	A
100002	1	Cash loans	M	N	Y	0	202500.0	
100003	0	Cash loans	F	N	N	0	270000.0	
100004	0	Revolving loans	M	Y	Y	0	67500.0	
100006	0	Cash loans	F	N	Y	0	135000.0	

- Target : 48 744 lignes et 121 colonnes

SK_ID_CURR	NAME_CONTRACT_TYPE	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT
100001	Cash loans	F	N	Y	0	135000.0	568800.0
100005	Cash loans	M	N	Y	0	99000.0	222768.0
100013	Cash loans	M	Y	Y	0	202500.0	663264.0
100028	Cash loans	F	N	Y	2	315000.0	1575000.0
100038	Cash loans	M	Y	N	1	180000.0	625500.0

ANALYSE EXPLORATOIRE

Dataframe : 307 511 lignes et 122 colonnes

Données dupliquées	Données manquantes
0	25% au total

Colonnes utiles pour classification :

Corrélations positives

- DAYS_BIRTH
- DAYS_EMPLOYED
- REGION_RATING_CLIENT_W_CITY
- REGION_RATING_CLIENT
- NAME_INCOME_TYPE_Working
- DAYS_LAST_PHONE_CHANGE

Corrélations négatives

- EXT_SOURCE_3
- EXT_SOURCE_2
- EXT_SOURCE_1
- NAME_EDUCATION_TYPE_Higher education
- CODE_GENDER_F
- NAME_INCOME_TYPE_Pensioner

Préparation du dataframe

Réduction de dimension

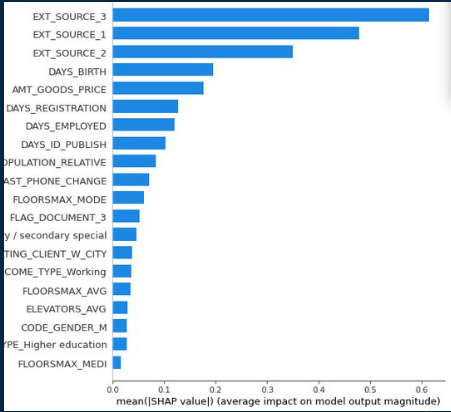

Gestion des anomalies

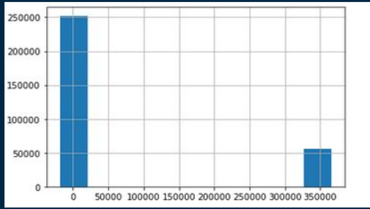

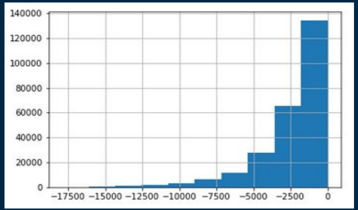

Label Encoding

State (Nominal Scale)	State (Label Encoding)
Maharashtra	3
Tamil Nadu	4
Delhi	0

One-Hot Encoding

Color
Red
Red
Yellow
Green
Yellow

Red	Yellow	Green
1	0	0
1	0	0
0	1	0
0	0	1

DATAFRAME FINAL

DAYS_BIRTH	DAYS_EMPLOYED	REGION_RATING_CLIENT_W_CITY	REGION_RATING_CLIENT	NAME_INCOME_TYPE_Working
-19241	-2329.0	2	2	1
-18064	-4469.0	2	2	1
-20038	-4458.0	2	2	1
-13976	-1866.0	2	2	1
-13040	-2191.0	2	2	1

48 744 lignes et 31 colonnes

Imputer

Scaler

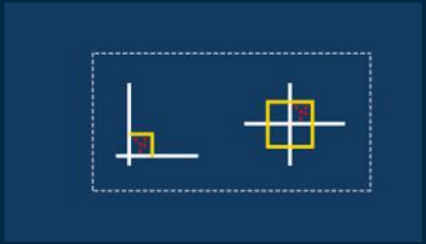

VISUALISATION DE L'OBJECTIF

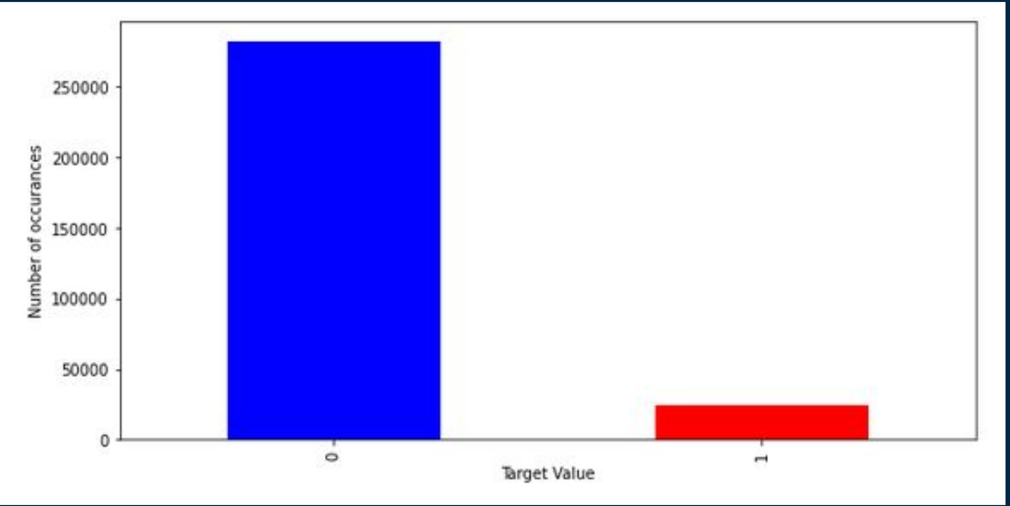

La variable 'TARGET' est fortement déséquilibrée

Métrique : ~~Accuracy~~

ENTRAINEMENT DES MODELES

02

Choix des modèles, de la métrique et de la technique d'échantillonnage

PREMIERS RESULTATS

LGBM Ridge Random Forest

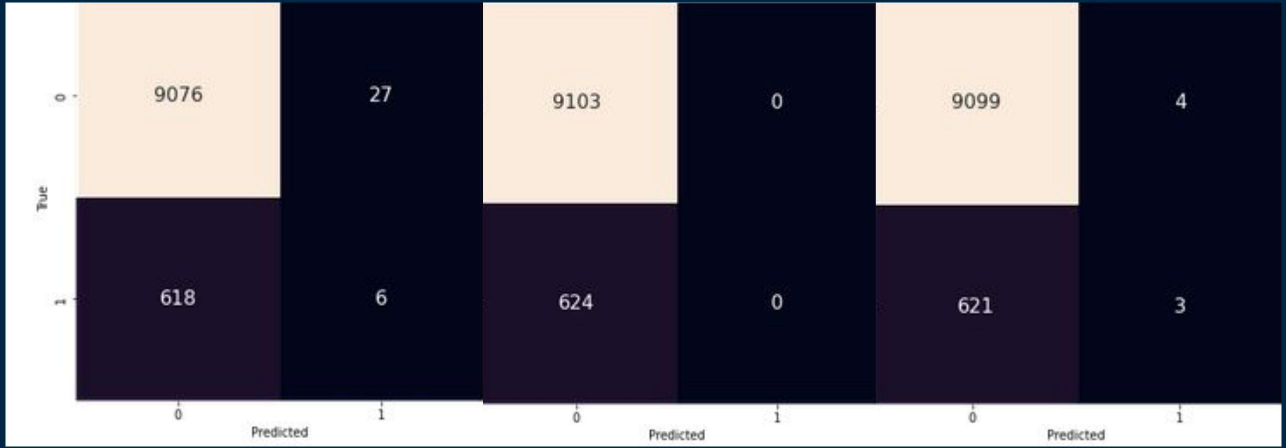

Précision	0.182	0	0.429
Rappel	0.010	0	0.005

- Accuracy élevée

⇒ 90% en moyenne

- Précision et rappel très faibles

Mauvaise prédiction

TECHNIQUE D'ÉCHANTILLONNAGE

Under-sampling

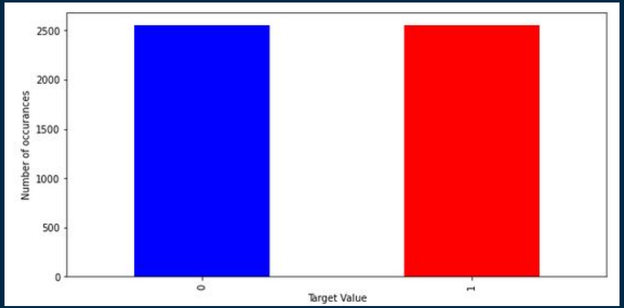

Over -sampling

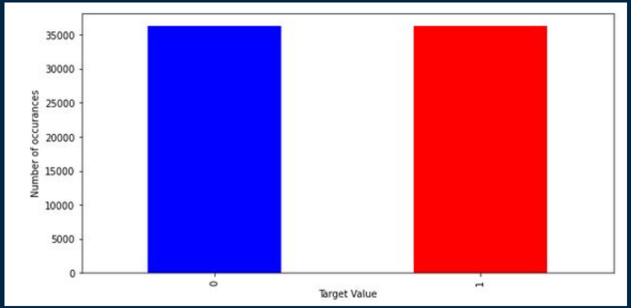

Class-Weight

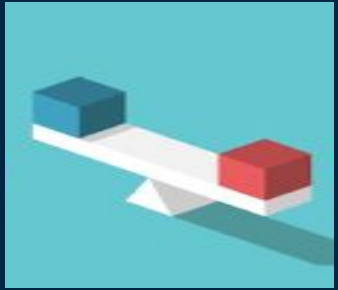

CHOIX DE LA MÉTRIQUE

True Class

Predicted Class

TP	FP
FN	TN

- Minimiser le taux de mauvais payeurs
- Maximiser le taux de bons payeurs

Choix de la métrique : Fβ-Score avec $\beta = 3$

RESULTATS Under-Sampling

LGBM | Ridge | Random Forest

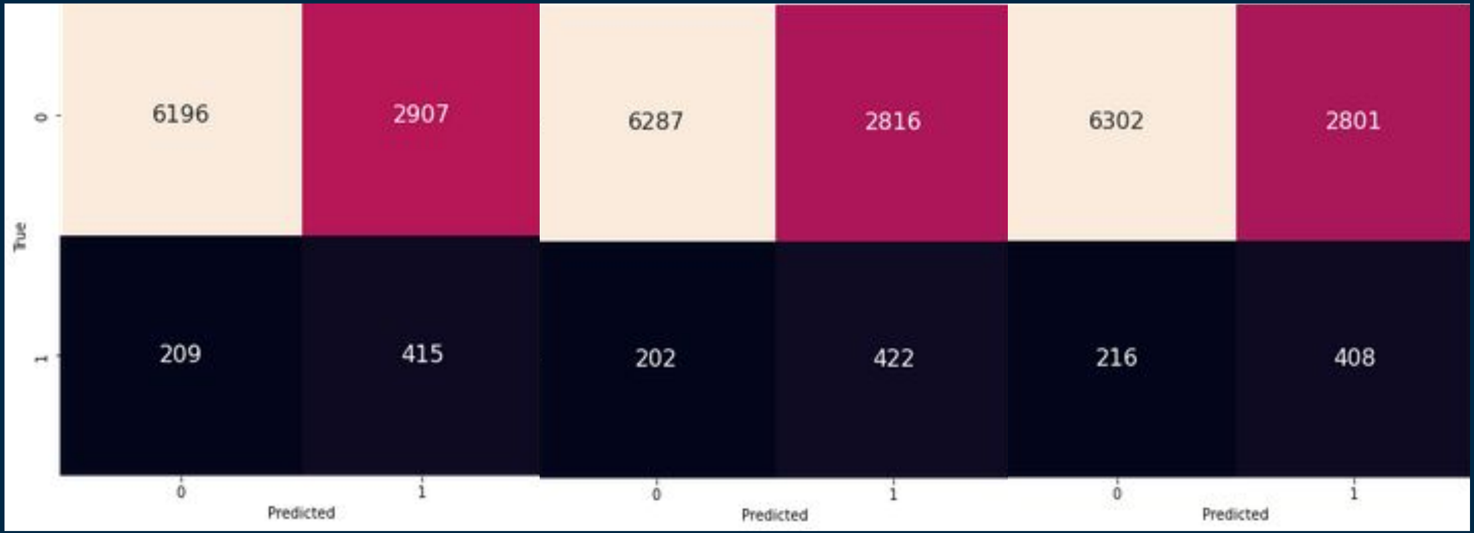

FB-Score	0.464	0.477	0.462

RESULTATS SMOTE

LGBM | Ridge | Random Forest

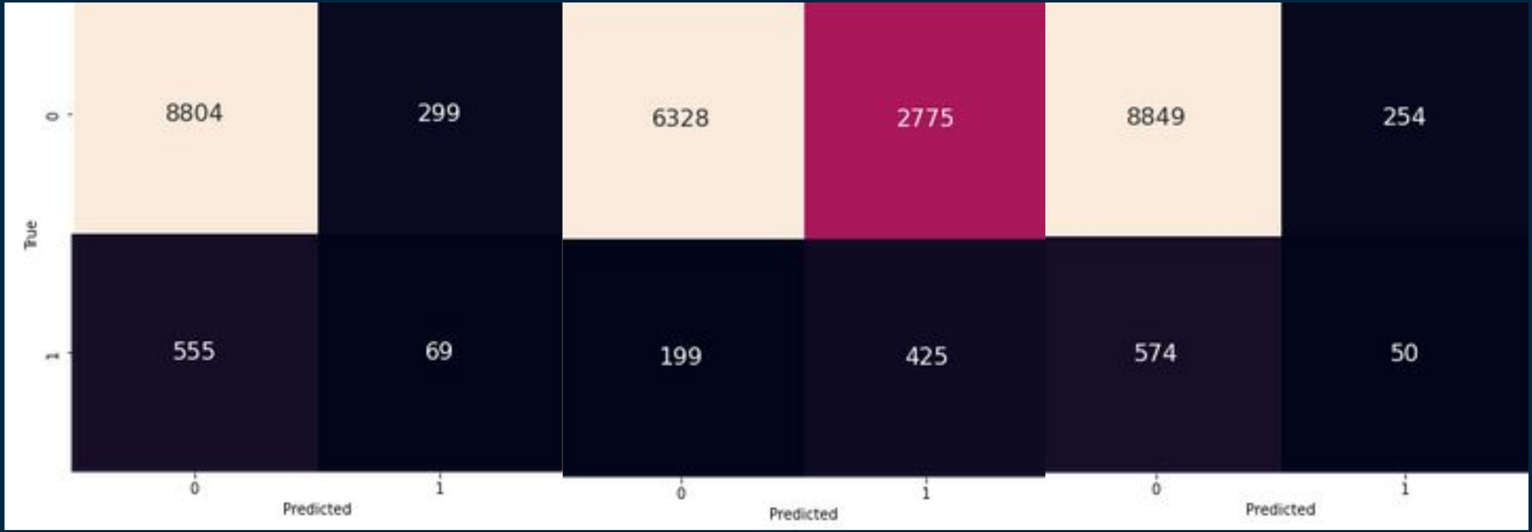

FB-Score	0.115	0.482	0.084

RESULTATS CLASS-WEIGHT

LGBM

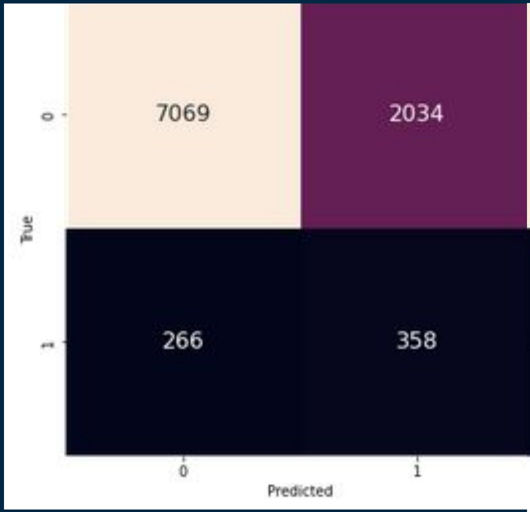

Ridge

Random Forest

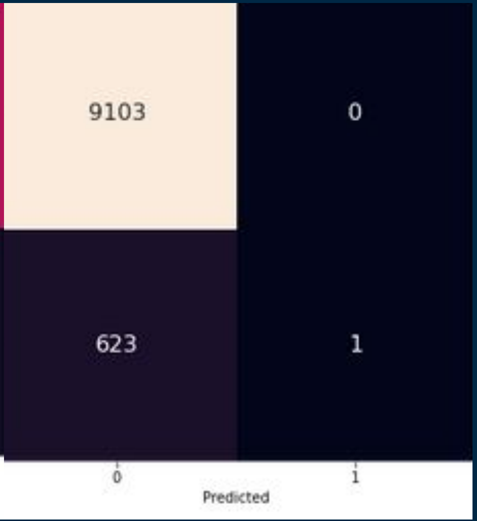

FB-Score	0.447	0.482	0.002

MODELE CHOISI

Modèle	Under-sampling	SMOTE	Class-Weight
LGBM	0.464	0.115	0.447
Random Forest	0.462	0.084	0.002
Ridge	0.477	0.482	0.482

Ridge meilleur score mais LGBM meilleure interprétabilité

INTERPRETABILITE

LIME

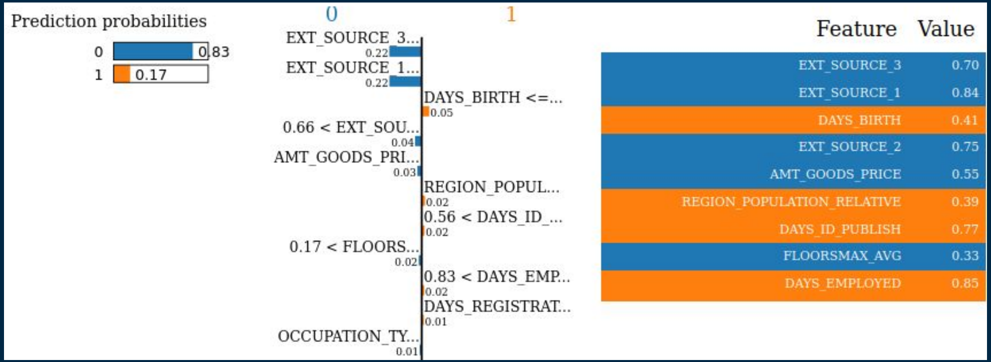

SHAP

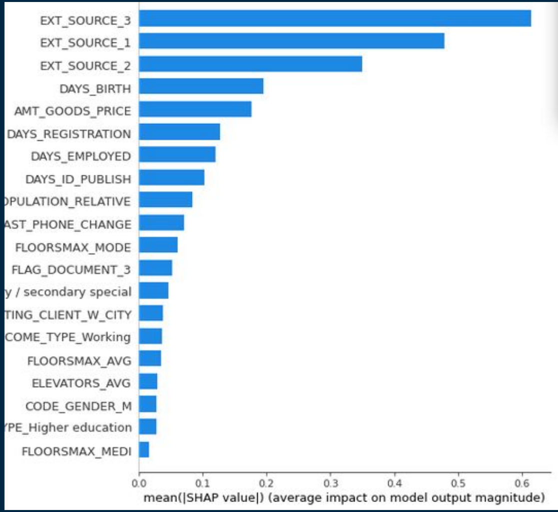

ENTRAINEMENT DE MODELE

```python
my_estimator = lgbm.LGBMClassifier(random_state = 42)
my_params = {
    'learning_rate': [0.05, 0.1, 0.15],
    'n_estimators': [50, 100, 150],
    'num_leaves': [25, 31, 37], # large num_leaves helps improve accuracy but might lead to over-fitting
    'boosting_type' : ['gbdt', 'dart'], # for better accuracy -> try dart
    'objective' : ['binary', None],
    'max_bin':[255, 510], # large max_bin helps improve accuracy but might slow down training progress
    'random_state' : [42],
    'colsample_bytree' : [0.99, 1, 1.01],
    'subsample' : [0.9, 1.0]
    }
```

```python
my_gridsearch = GridSearchCV(estimator=my_estimator, param_grid=my_params, scoring=my_scorer, cv=cv)
my_gridsearch.fit(X_resampled, y_resampled)
```

```
GridSearchCV(cv=RepeatedKFold(n_repeats=3, n_splits=10, random_state=42),
             estimator=LGBMClassifier(random_state=42),
             param_grid={'boosting_type': ['gbdt', 'dart'],
                         'colsample_bytree': [0.99, 1, 1.01],
                         'learning_rate': [0.05, 0.1, 0.15],
                         'max_bin': [255, 510], 'n_estimators': [50, 100, 150],
                         'num_leaves': [25, 31, 37],
                         'objective': ['binary', None], 'random_state': [42],
                         'subsample': [0.9, 1.0]},
             scoring=make_scorer(fbeta_score, beta=3))
```

FB-Score = 0.464

DASHBOARD ET API 03

Streamlit & FastAPI

STREAMLIT

https://share.streamlit.io/pauloledes/projet7_oc/client_streamlit.py

Dashboard interactif

Ce dashboard a pour but d'aider les chargés de relation client afin qu'ils puissent à la fois expliquer de façon la plus transparente possible les décisions d'octroi de crédit, mais également permettre à leurs clients de disposer de leurs informations personnelles et de les explorer facilement.

Dans le cas où la prédiction de remboursement est inférieure à 60 %, une tentative d'amélioration de ce dernier est proposée.

Prêt à dépenser

Merci d'entrer un identifiant client :

100001

Prédictions de remboursement

	ID	Prediction
0	100001	0.4516

Ce client a 45 % de chances de rembourser

Prêt refusé ! ❌

Position du client 100001 dans la base des nouveaux clients

Les probabilités de remboursement de la part de ce client sont modérées mais il est possible de modifier certains de ses termes pour améliorer ses chances.

Vue générale

Notre client

	Age	Années d'emploi	Ancienneté banque	Annuité	Crédit demandé	Durée d'endettement
100001	52	6	14	20560	568800	27

Comparaison de notre client avec les rembourseurs et non-rembourseurs

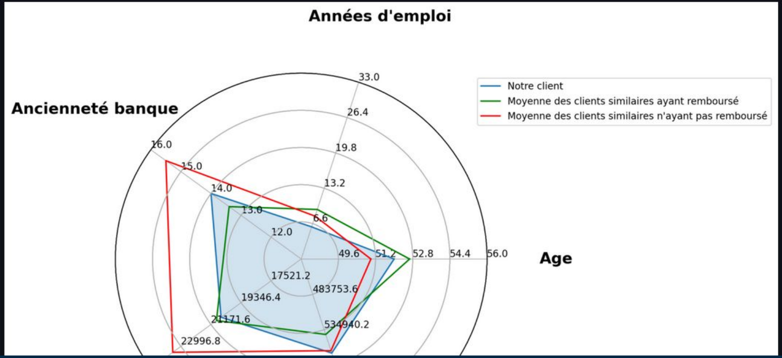

FastAPI

https://sleepy-beyond-12325.herokuapp.com

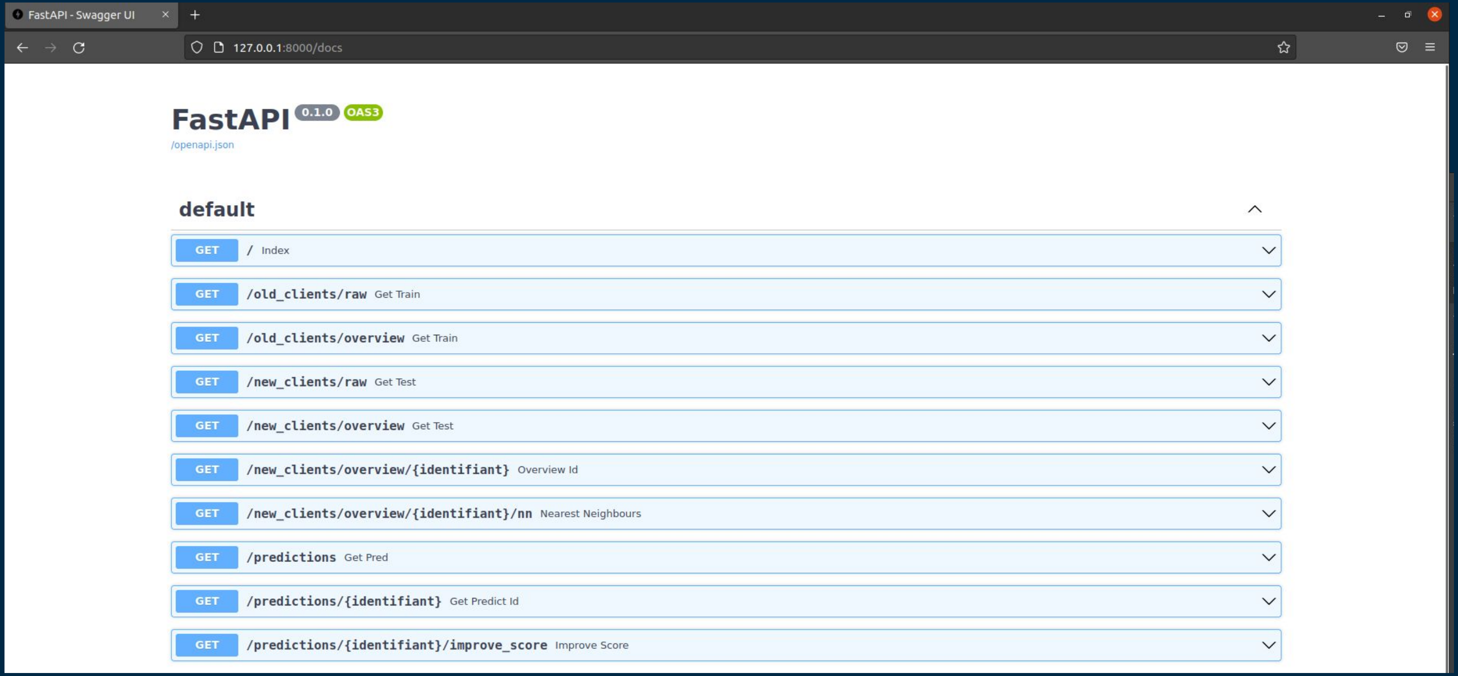

CONCLUSION

- β=3 à confirmer
- + de caractéristiques exploitables
- Limité par l'interprétabilité

MERCI POUR VOTRE ATTENTION !